

Predição de Pilotos no Top 10 da Fórmula 1 Utilizando Aprendizado de Máquina

Tauan Novaes Alves, João Pedro de Souza

Curso de Ciência da Computação

Facape

E-mail: ttuannovaes@gmail.com / joaopedrosouzarodri@gmail.com

Resumo

Este trabalho apresenta o desenvolvimento de um modelo de aprendizado de máquina para prever se um piloto da Fórmula 1 terminará uma corrida entre os dez primeiros colocados utilizando apenas informações disponíveis antes da largada. Foram avaliados diferentes algoritmos de classificação, incluindo Random Forest, Regressão Logística e Gradient Boosting. Os resultados demonstraram que o modelo Gradient Boosting obteve o melhor desempenho, alcançando F1-Score de 95,2% e acurácia de 95,2%. Além da modelagem, foi implementado um pipeline completo de ciência de dados com monitoramento e disponibilização por API. Os resultados indicam que técnicas de aprendizado de máquina podem auxiliar na previsão de desempenho esportivo em competições automobilísticas.

Palavras-chave: Fórmula 1, Machine Learning, Classificação, Ciência de Dados, Gradient Boosting.

1. Introdução

A Fórmula 1 é uma das competições automobilísticas mais complexas do mundo, envolvendo diversos fatores que influenciam o desempenho dos pilotos, como posição de largada, condições climáticas, equipe, circuito e estratégia. A capacidade de prever o resultado de uma corrida antes da largada possui grande relevância para equipes esportivas, analistas de desempenho e mercados de apostas.

Neste contexto, técnicas de Ciência de Dados e Aprendizado de Máquina podem ser utilizadas para estimar a probabilidade de um piloto terminar uma corrida entre os dez primeiros colocados, região responsável pela pontuação oficial do campeonato. O objetivo deste trabalho é desenvolver e avaliar modelos de classificação capazes de prever se um piloto terminará uma corrida no Top 10 utilizando apenas informações disponíveis antes do início da prova, evitando problemas de vazamento de dados (data leakage). O projeto

implementa um pipeline completo de ciência de dados, incluindo preparação dos dados, engenharia de atributos, treinamento, avaliação, monitoramento e disponibilização do modelo por meio de uma API.

2. Dados

O conjunto de dados utilizado foi obtido no Kaggle e contém informações históricas da Fórmula 1 enriquecidas com variáveis meteorológicas e características relacionadas às corridas. Inicialmente, o dataset possui aproximadamente 69.230 registros distribuídos em 29 atributos, onde cada linha representa uma volta realizada por um piloto durante uma corrida. Após o processo de agregação, os dados foram transformados em 1.247 observações correspondentes aos resultados finais das corridas realizadas entre 2021 e 2023.

A variável alvo do problema é denominada **top10**, sendo definida como:

- **top10 = 1**: piloto terminou entre os dez primeiros colocados;
- **top10 = 0**: piloto terminou fora da zona de pontuação.

Foram utilizadas apenas informações conhecidas antes da largada, incluindo:

- Posição de largada (grid);
- Etapa da temporada (round);
- Ano da corrida;
- Temperatura da pista;
- Temperatura ambiente;
- Umidade;
- Índice de chuva;
- Velocidade do vento;
- Identificador da equipe (constructorId);
- Identificador do circuito (circuitId).

Durante a análise exploratória dos dados (EDA), verificou-se que a distribuição das classes apresenta relativo equilíbrio, aproximadamente 50% para cada categoria. Isso permite o uso de métricas tradicionais como acurácia, além de métricas mais robustas para classificação binária, como F1-Score e AUC-ROC.

3. Metodologia

O projeto foi estruturado seguindo as principais etapas de um pipeline de Machine Learning.

3.1 Preparação dos Dados

Inicialmente, os dados brutos foram submetidos a um processo de limpeza e padronização. Em seguida, registros por volta foram agregados para gerar uma única observação por piloto em cada corrida. Após essa etapa, foi criada a variável alvo responsável por indicar se o piloto terminou ou não entre os dez primeiros colocados.

3.2 Engenharia de Atributos

Para evitar vazamento de informação, foram removidas variáveis que somente estariam disponíveis durante ou após a corrida, tais como:

- Posição durante a prova;
- Tempos de volta;
- Número de voltas;
- Estratégia de pneus;
- Status de finalização da corrida.

A exclusão dessas variáveis garante que o modelo opere em um cenário realista de previsão pré-corrida.

3.3 Modelos Avaliados

Foram treinados cinco modelos supervisionados de classificação:

1. Random Forest (100 árvores);
2. Random Forest (200 árvores);
3. Regressão Logística ($C = 1,0$);
4. Regressão Logística ($C = 0,5$);
5. Gradient Boosting Classifier.

O gerenciamento dos experimentos foi realizado utilizando a plataforma MLflow, permitindo registrar métricas, parâmetros e versões dos modelos treinados.

3.4 Validação

A avaliação foi realizada utilizando:

- Conjunto de teste estratificado (20%);
- F1-Score;
- Precisão;
- Recall;
- Acurácia;
- AUC-ROC;
- Validação cruzada com Stratified K-Fold de 10 partições.

4. Resultados

Os resultados obtidos demonstram elevado desempenho dos modelos avaliados.

Modelo	Accuracy	F1	Precisio n	Recall	AUC-ROC
Random Forest (100)	0,948	0,949	0,938	0,960	0,994
Random Forest (200)	0,948	0,949	0,931	0,968	0,993
Logistic Regression (C=1.0)	0,880	0,882	0,868	0,896	0,930
Logistic Regression (C=0.5)	0,884	0,886	0,869	0,904	0,932
Gradient Boosting	0,952	0,952	0,945	0,960	0,985

O melhor desempenho foi alcançado pelo modelo **Gradient Boosting Classifier**, apresentando F1-Score de 95,2% e acurácia de 95,2%. O resultado indica alta capacidade do modelo em identificar corretamente os pilotos que terminarão na zona de pontuação.

A validação cruzada apresentou F1 médio de **0,947 ± 0,021**, evidenciando estabilidade e capacidade de generalização do modelo para diferentes subconjuntos dos dados.

Além da modelagem, o projeto disponibiliza uma API desenvolvida em FastAPI para realização de predições em tempo real, bem como um mecanismo de monitoramento de drift que compara distribuições históricas e atuais dos atributos utilizados pelo modelo.

5. Conclusão e Trabalhos Futuros

Os resultados obtidos demonstram que técnicas de aprendizado de máquina podem ser utilizadas com sucesso para prever o desempenho de pilotos de Fórmula 1 antes do início das corridas. O modelo Gradient Boosting apresentou excelente desempenho, alcançando métricas superiores a 95% de F1-Score e acurácia.

A principal contribuição do projeto é a construção de um pipeline completo e realista de Ciência de Dados, contemplando desde a preparação dos dados até a disponibilização do modelo em produção por meio de API e monitoramento contínuo.

Entretanto, algumas limitações foram identificadas. As variáveis climáticas foram representadas por médias observadas durante a corrida, enquanto em um ambiente real seriam utilizadas previsões meteorológicas. Além disso, os identificadores de equipes e circuitos não possuem enriquecimento semântico, dificultando a interpretação dos resultados. Outro fator importante é que os dados abrangem apenas as temporadas de 2021 a 2023, exigindo monitoramento e re-treinamento para futuras temporadas.

Como trabalhos futuros, recomenda-se:

- Inclusão de dados das temporadas mais recentes;
 - Utilização de rankings históricos dos pilotos;
 - Incorporação de estatísticas de classificação;
 - Uso de técnicas de explicabilidade como SHAP;
 - Implantação contínua do modelo em ambiente de produção.
-

Referências

1. Projeto GitHub: [projeto-cc-av2](#)
2. Kaggle Formula 1 Dataset with Weather and Tyre Features. Disponível em: <https://www.kaggle.com>
3. PEDREGOSA, F. et al. Scikit-Learn: Machine Learning in Python. Journal of Machine Learning Research, 2011.
4. CHEN, T.; GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. KDD, 2016.
5. MLFLOW. Machine Learning Lifecycle Platform. Disponível em: <https://mlflow.org>
6. FASTAPI. Modern Python Web Framework. Disponível em: <https://fastapi.tiangolo.com>